



Machine Learning Project

Bank Marketing

Pierre Jean et Karl Sondeji

April 18, 2023



¶ Table des matières :

Analyse des données	3
Préface	3
Analyse de notre base de données	4
Visualisation de nos données	6
Matrice de corrélation	7
Problématique	8
Le problème	8
K-plus proches voisins (KNN)	9
Préparation des données	9
recherche du meilleur voisin	9
LDA/QDA	10
Analyse Linéaire Discriminante (LDA)	10
Analyse Quadratique Discriminante (QDA)	10
SVM radial	11
Optimisation du paramètre sigma	11
CART	13
Arbre réalisé avec <code>r.part</code>	13
Optimisation automatique avec <code>Caret</code>	13
Test de notre CART réalisé avec <code>Caret</code>	14
Métriques & Performances	14
Matrice de confusion	14
Random Forest	15
tree/error	15
Analyses	15
Importance des variables	16
erreur.min	17
Hétérogénéité et variance	18
Variables importantes	18
Courbe ROC	18

Boosting	19
recherche du meilleur modèle	19
Erreur d'apprentissage	20
Précision du modèle	20
Comparaisons de modèles	21
Rappel	21
Conclusion	21


Analyse des données

Préface

Les données sont liées à des campagnes de marketing direct (par appels téléphoniques) d'une institution bancaire portugaise. Ces campagnes nécessitant d'énormes investissements, il est vital pour les banques d'identifier au préalable les clients les plus susceptibles de souscrire, afin de les cibler en priorité. La variable que nous allons tenter de prédire est y le client souscrira-t-il à un dépôt à terme ? (**yes**, **no**)

Nous décidons de procéder brièvement à une petite analyse concernant les données manquantes de notre base de données. Pour cela, nous avons représenté dans un tableau le nombre d'observations où figurent des données manquantes. Puis, à l'aide d'une représentation graphique, nous pourrions regarder quelles variables ont le plus de valeurs manquantes.

Analyse de notre base de données



- À première vue on pourrait croire que notre base de données ne contient pas de valeurs manquantes, mais c'est simplement qu'elles ont été codées par "unknown" pour la suite de notre étude, nous allons soit les laisser telles qu'elles sont soit les enlever si elles perturbent la réalisation de nos modèles.

ainsi on sait que:

- la variable **education** possède 0.04% de NA
- la variable **contact** possède 0.29% de NA
- la variable **poutcome** possède 0.82% de NA

```
## [1] FALSE
```

pas de lignes duppliquées dans notre base de données

- Quelques statistiques sur notre base de données

```


##          age          job          marital          education
##  Min.    :18.00  blue-collar:9732  single   :12790  unknown   : 1857
## 1st Qu.:33.00  management :9458  divorced: 5207  primary    : 6851
## Median :39.00  technician :7597  married  :27214  secondary:23202
## Mean    :40.94  admin.     :5171          tertiary :13301
## 3rd Qu.:48.00  services   :4154
## Max.    :95.00  retired    :2264
##          (Other)   :6835
##  default      balance      housing      loan      contact
##  no :44396  Min.    : -8019  no :20081  no :37967  unknown   :13020
##  yes: 815  1st Qu.: 72    yes:25130  yes: 7244  cellular   :29285
##          Median : 448          telephone: 2906
##          Mean    : 1362
##          3rd Qu.: 1428
##          Max.    :102127
##
##          day          month          duration          campaign
##  Min.    : 1.00  may      :13766  Min.    : 0.0  Min.    : 1.000
## 1st Qu.: 8.00  jul      : 6895  1st Qu.: 103.0  1st Qu.: 1.000
## Median :16.00  aug      : 6247  Median : 180.0  Median : 2.000
## Mean    :15.81  jun      : 5341  Mean    : 258.2  Mean    : 2.764
## 3rd Qu.:21.00  nov      : 3970  3rd Qu.: 319.0  3rd Qu.: 3.000
## Max.    :31.00  apr      : 2932  Max.    :4918.0  Max.    :63.000
##          (Other): 6060
##  pdays      previous      poutcome      y
##  Min.    : -1.0  Min.    : 0.0000  unknown:36959  no :39922
## 1st Qu.: -1.0  1st Qu.: 0.0000  other : 1840    yes: 5289
## Median : -1.0  Median : 0.0000  failure: 4901
## Mean    : 40.2  Mean    : 0.5803  success: 1511
## 3rd Qu.: -1.0  3rd Qu.: 0.0000
## Max.    :871.0  Max.    :275.0000
##

```

On se rend compte que la modalité **yes** de notre variable **y** est sous représentée, 11.7% de nos données. 50% de nos clients ont moins de 40 ans, 75% de nos clients n'avaient jamais été contacté avant. Pour la variable **duration** l'écart-type est plus élevé que la médiane, on constate un saut énorme entre le 3ème quartile et la valeur maximale, même remarque pour la variable **balance**. Si cela devait être problématique pour la performance de nos modèles, on pourrait fixer une valeur maximale.


$$99\% \in [\mu - 3 \times \sigma, \mu + 3 \times \sigma]$$

Visualisation de nos données



Pour

la variables default on peut voir qu'aucun individu qui a déjà été en défaut n'a soucrit un abonnement. Pour ce qui est des autres variables elles sont difficiles a interpréter car on sait que la modalité **yes** est sous-représentée.




Pour

les variables continues, on voit que l'on a plus de chances de faire souscrire un client, lorsqu'on le contacte en début de mois ou vers le 12 du mois, lorsque celui-ci a plus de 60 ans, ou lorsque les appels ont tendances à dépasser les 1000 secondes.

Matrice de corrélation

On voit dans cette matrice que les seules variables fortement corrélées entre elles sont `previous` et `pdays` ainsi que `y` et `duration`. Pour rappel l'autocorrélation peut causer une baisse des performances de prédiction des modèles de régression en raison d'une mauvaise généralisation à de nouvelles données, elle rend l'identification des variables importantes plus difficile, peut conduire à un sur-ajustement des modèles, ce qui signifie que les modèles sont trop complexes.



Problématique

Au travers cette étude, nous allons chercher à voir comment, au moyen de méthodes de machine learning, nous allons pouvoir identifier les caractéristiques propres des groupes constituant notre clientèle, de sorte à pouvoir prédire au mieux si un client souscrira à un dépôt à terme.

Le problème

Dans la suite de ce TP, on utilisera systématiquement l'algorithme SMOTE (Synthetic Minority Over-sampling Technique) pour corriger le sur-échantillonnage de la modalité **yes**.

$$\mathbf{x}_{\text{nouveau}} = \mathbf{x}_{\text{minorité}} + \text{Bin}(0, 1) \times (\mathbf{x}_{\text{voisins}} - \mathbf{x}_{\text{minorité}})$$

La métrique la plus importante dans notre cas est le rappel. En effet, nous voulons que l'équipe marketing cible les clients les plus susceptibles d'accepter l'abonnement au dépôt à terme, et le rappel mesure la proportion de vrais positifs (c'est-à-dire les clients qui souscriraient au dépôt à terme) parmi tous les cas positifs réels (c'est-à-dire, clients intéressés à s'abonner). En optimisant le rappel, nous pouvons nous assurer que l'équipe marketing touche autant de clients intéressés que possible et maximise le potentiel de réussite de l'abonnement.


K-plus proches voisins (KNN)

Préparation des données

on convertit tout les facteurs en variables numériques avant de les mettre à la même échelle, c'est une forme de normalisation que l'on a appliqué aux données, afin d'éviter les biais de modèle, en équilibrant l'importance relative des caractéristiques (redondantes ou peu importantes) qui ont tendances à causer du biais.


recherche du meilleur voisin

Pour déterminer le nombre de voisin qui nous donne le meilleur modèle, en utilisant la métrique précision, nous allons faire tourner une grille de 15 voisins compris entre 1 et 30 avec un pas de 2.



17 et 25 voisins qui nous donnent les meilleurs taux de prédiction, soit 88.7640449, mais on choisira 17 voisins.

- Matrice de confusion avec 17 voisins



Avec 17 voisins, on obtient une précision de 88.97%.

LDA/QDA

Analyse Linéaire Discriminante (LDA)


Pour la LDA/QDA et la SVM nous avons enlever les variables contenant trop de *NA* et enlever les individus contenant des *NA* pour les variables contenant peu de valeurs manquantes. Pour sélectionner les meilleurs modèles, nous utiliserons la validation croisée.


Analyse Quadratique Discriminante (QDA)

Pour entraîner notre modèle, on utilisera uniquement les variables catégorielles.

SVM radial

Optimisation du paramètre sigma






CART

Arbre réalisé avec `r.part`


Optimisation automatique avec `Caret`



le meilleur paramètre de complexité pour cet arbre élagué est de 0.001328

Test de notre CART réalisé avec *Caret*

Métriques & Performances




Avec la métrique *ROC* on trouve pour meilleure complexité 3.3200531×10^{-4} , en optimisant automatiquement.

Matrice de confusion

	Prédiction		Sum
	no	yes	
no	9162	718	9880
yes	381	538	919
Sum	9543	1256	10799

Random Forest


tree/error



Analyses


Plus le nombre d'arbres de notre forêt augmente plus l'erreur d'apprentissage diminue, ici on prendra potentiellement 300 arbres. Le OOB est une moyenne pondérée des yes et des no donc c'est normal qu'elle soit entre les deux, il y a déséquilibre entre yes et no les *yes* représentent 0.117% de nos données, donc si on arrive mieux à prédire les no que les yes c'est tout simplement parce que nous ne disposons pas d'assez de *yes* dans l'échantillon d'entraînement.

Importance des variables



q est

le nombre de variables que l'on autorise notre modèle à regarder lors de son apprentissage, de sorte à décorréliser les branches entres et permettre à notre modèle de ressortir e moins d'informations redondantes possibles. - pas assez de variables discriminantes pour qu'on ait $q=1$ pertinent, c'est pourquoi on a un pic de début assez haut pour q1, on voit qu'en fonction du nombre de q le premier pic descend.


erreur.min

En utilisant le *Bagging*, le nombre d'arbres minimisant l'erreur OOB est 375, qui atteint la valeur de 0.092%.

Hétérogénéité et variance

Variables importantes

Random Forest




Courbe ROC

Notre modèle semble avoir une précision sur les données de test presque suspecte.

	Prédiction		Sum
	no	yes	
no	9981	48	10029
yes	0	1275	1275
Sum	9981	1323	11304

Boosting

recherche du meilleur modèle



Nous avons essayer 4 types d'arbres différents pour notre **Boosting** afin de sélectionner le meilleur modèle. Un arbre complet **boost1**, un arbre pénalisé **pen01**, une souche **stump**, et une souche pénalisée **stumpen01**. L'arbe qui nous donne la meilleure erreur d'apprentissage est sans surprise l'arbre complet, mais nous le conserverons car son erreur-test reste bonne.

Erreur d'apprentissage




En

utilisant la validation croisée, nous avons testé l'erreur d'apprentissage en fonction de la profondeur des branches, la profondeur optimale est 8.

Précision du modèle

	Prédiction		Sum
	no	yes	
no	9633	684	10317
yes	348	639	987
Sum	9981	1323	11304

Comparaisons de modèles



Les modèles avec la plus grande AUC sur les données test, sont le Boosting et le Random_forest.

Rappel

$$Rappel = \frac{VraiPositifs}{VraiPositifs + FauxPositifs}$$

Conclusion

un modèle tel que le KNN est assez simple à mettre en place et fournit une bonne précision, mais si on veut encore plus de précision, on peut opter pour un Boosting ou encore un Random forest même si ces derniers, ayant plusieurs paramètres à optimiser sont parfois beaucoup plus long à construire. Toutefois la mesure qui nous intéresse le plus étant le rappel, nous choisirons donc le modèle avec le plus grand rappel car c'est cela qui intéresse le plus notre banque si elle veut cobler les clients ayant le plus de chance de souscrire à un abonnement, nous conserverons donc le Boosting avec un rappel de 0.9337017.